LabFlow AI

Guía de entregables: qué pide cada uno y cuál es el nuestro

El cuaderno de laboratorio que escucha, organiza y analiza. Un asistente por voz, con interfaz web y versión móvil, para registrar, verificar y analizar mediciones en laboratorios de ingeniería química.

Para cada uno de los seis entregables este documento explica, primero, **qué pide** (el propósito y las partes que se esperan) y después **cuál es en nuestro proyecto**, con lo que ya está construido en el repositorio. Donde el producto cambió respecto al documento de requerimientos v0.3, se indica.

#	Entregable	Dónde vive en el repositorio
1	Descripción del producto y especificación de requerimientos	docs/product/producto-y-requerimientos-v0.3.md · docs/scope/scope.md
2	ML Canvas	docs/product/ml-canvas-v1.md
3	Mockups de la UI	web/design.md · spec 0003 (sistema de diseño) · spec 0010 (móvil)
4	Diseño arquitectónico	spec 0001 (stack y arquitectura) · spec 0002 (modelo de datos)
5	Diseño de pruebas	verify.md de cada spec · api/tests · web/src/**/*.test.* · web/e2e
6	Selección de modelos y model card	spec 0001, 0006 y 0007 · api/app/core/settings.py

La propuesta en una frase: mientras el estudiante trabaja con las manos ocupadas, LabFlow convierte lo que dice en datos estructurados que el código verifica y el usuario confirma, y que luego puede consultar, graficar y exportar.

1. Descripción del producto y especificación de requerimientos

Qué pide
Explicar qué es el producto y por qué existe (problema, usuarios, propuesta de valor) y convertirlo en requerimientos verificables: historias de usuario, requerimientos funcionales (qué hace) y no funcionales (con qué calidad: latencia, precisión, seguridad), con prioridad y criterio de aceptación, más reglas de negocio, modelo de datos conceptual y alcance (qué entra y qué no).

Cuál es en LabFlow AI

Problema. En una práctica de laboratorio, medir y anotar compiten por las mismas manos. Hay errores de transcripción (un 46 copiado como 64), datos incompletos que se descubren al final y trabajo repetido al pasar todo a Excel.

Usuarios. Estudiante de laboratorio (principal), auxiliar de investigación y profesor (secundario).

Propuesta de valor. Dictar o escribir una medición, ver lo que LabFlow entendió y obtener tabla, gráfica y resumen al momento, sin cifras inventadas. Metas: ≥ 30 % menos tiempo documentando, 0 % de campos requeridos vacíos, 100 % de valores guardados iguales a lo dictado.

Requerimientos funcionales (selección)

ID	Requerimiento	Prioridad	Estado en el prototipo
RF-01/02	Crear, listar y abrir cuadernos con variables (unidad, rango, requerida)	Imprescindible	Hecho; también desde instrucciones en PDF o texto
RF-03	Registrar por voz	Imprescindible	Hecho: conversación con agente de voz
RF-04	Registrar por texto	Imprescindible	Hecho
RF-05/06	Mostrar propuesta, confirmar y corregir	Imprescindible	Hecho; las lecturas limpias se guardan solas con Deshacer
RF-07	Pedir aclaración ante datos incompletos o ambiguos	Imprescindible	Hecho
RF-09/10	Tabla de ensayos y gráfica X vs. Y	Imprescindible	Hecho
RF-11	Máximo, mínimo, promedio y conteo con ensayo de origen	Imprescindible	Hecho como resumen por variable y mejor ensayo
RF-12	Advertir valores fuera de rango	Deseable	Hecho: valores marcados para revisar
RF-14/15	Instrucciones en PDF y exportar CSV	Deseable	Hecho (PDF para proponer el cuaderno)

Requerimientos no funcionales

ID	Atributo	Criterio
RNF-01	Idioma	Español; números en palabras y decimales con «coma» o «punto»
RNF-02	Latencia	Propuesta en ≤ 5 s desde el fin del dictado (objetivo 3 s)
RNF-03	Precisión	≥ 90 % del set de prueba sin corrección

ID	Atributo	Criterio
RNF-04	Confiabilidad	Cero cifras inventadas: cada número se busca en la frase por código
RNF-05	Trazabilidad	Frase original, quién guardó, cuándo y si fue automático
RNF-07	Plataforma	Navegador en laptop y, desde la versión móvil, en el teléfono (instalable)
RNF-08	Seguridad	Claves solo en el servidor; código de acceso; no se guarda audio
RNF-09	Tolerancia a fallos	Si falla la voz, el texto sigue funcionando; si falla un modelo, entra el otro

Reglas de negocio y modelo de datos

- **Unidades:** cada variable tiene su unidad; «grados» → °C, «por ciento» → %. La unidad se bloquea cuando ya hay valores guardados.
- **Ensayo repetido:** si el número ya existe, se pregunta si es corrección o ensayo nuevo.
- **Origen de las respuestas:** todo mínimo y máximo dice de qué ensayos sale.
- **Entidades:** Cuaderno (experimento), Variable, Ensayo, Medición, Propuesta (la tarjeta), Turno de conversación e Instrucciones.

Alcance. Dentro: acceso por código, cuadernos, captura por voz y texto, tabla, gráfica, resumen, variables editables, versión móvil. Fuera: instrumentos reales, permisos por usuario, validación regulatoria, preguntas libres sobre los datos (función 10, planeada).

2. ML Canvas

Qué pide
Una página (plantilla de Louis Dorard, OwnML) que obliga a pensar el componente de aprendizaje automático como producto: qué se predice, qué decisión se toma con esa predicción, para quién crea valor, de dónde salen y cómo se etiquetan los datos, cómo se evalúa antes y después de desplegar, y cómo se vigila. Son 10 bloques que se llenan de forma concisa.

Cuál es en LabFlow AI (iteración actualizada)

Bloque	Qué responde	En LabFlow
Prediction task	¿Qué predice el sistema?	Por cada frase: la intención (registrar, corregir, elegir ensayo, confirmar, descartar, aclarar) y los campos {ensayo, variable, valor, unidad}, o «falta información».
Decisions	¿Qué decisión se toma con la predicción?	Si todo cuadra (cada número está en la frase, en rango, sin ambigüedad) se guarda solo con «Deshacer»; si no, se muestra la tarjeta y se pregunta. La IA nunca calcula cifras.
Value proposition	¿Para quién y qué gana?	Estudiantes y auxiliares de ingeniería química: dictar sin soltar lo que hacen, menos errores de transcripción, faltantes avisados a tiempo.
Data collection	¿Cómo se consiguen datos etiquetados?	Set inicial de 30–50 frases etiquetadas a mano; cada propuesta y su versión confirmada o corregida es un nuevo par etiquetado.
Data sources	¿De dónde vienen los datos?	Definición del cuaderno (variables, unidades, rangos), transcripción del agente de voz, mediciones confirmadas con su frase, instrucciones en PDF.
Impact simulation	¿Cómo sabemos que sirve antes de usarlo?	Prueba en vivo y set de evaluación antes de cambiar prompt o modelo. Despliegue si: ≥ 90 % por campo, 0 cifras inventadas, ≤ 5 s.
Making predictions	¿Cuándo y con qué recursos?	En tiempo real, una por frase; ≤ 5 s; modelos en la nube llamados desde el servidor.
Building models	¿Cómo se construyen y actualizan?	No se entrena: modelos preentrenados. Se actualiza el prompt, el esquema de herramientas o el modelo, y se valida con el set.
Features	¿Con qué información predice?	La frase, las variables con unidades y rangos, la tarjeta pendiente, los ensayos guardados, la última pregunta y el contexto del cuaderno.
Monitoring	¿Cómo se vigila en producción?	Una línea de log por turno: proveedor usado, latencia y motivo de respaldo; % de tarjetas corregidas y de aclaraciones.

Cambio frente a la iteración 1: la decisión ya no es «guardar solo tras confirmar». Ahora el **código** decide qué lectura es limpia y la guarda con opción de deshacer; la confianza del modelo nunca entra en la decisión.

3. Mockups de la UI

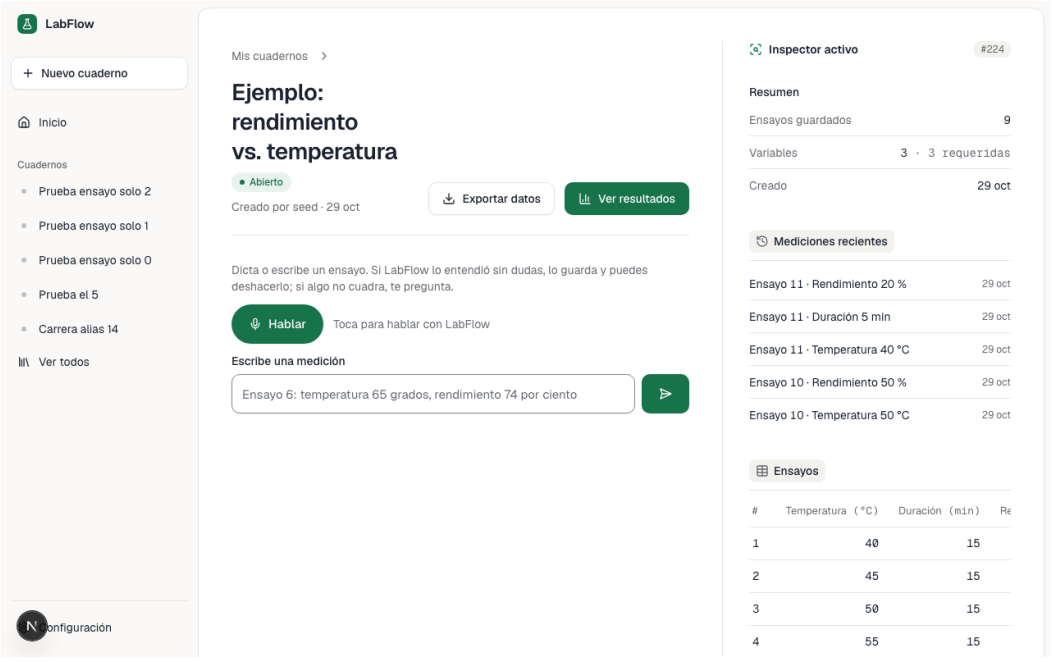
Qué pide
Mostrar cómo se verá y se usará el producto antes (o mientras) se construye: el inventario de pantallas, el flujo entre ellas y el diseño de las piezas clave, con suficiente detalle para validar con usuarios. Puede ser de baja fidelidad (bocetos) o alta fidelidad (diseño final).

Cuál es en LabFlow AI

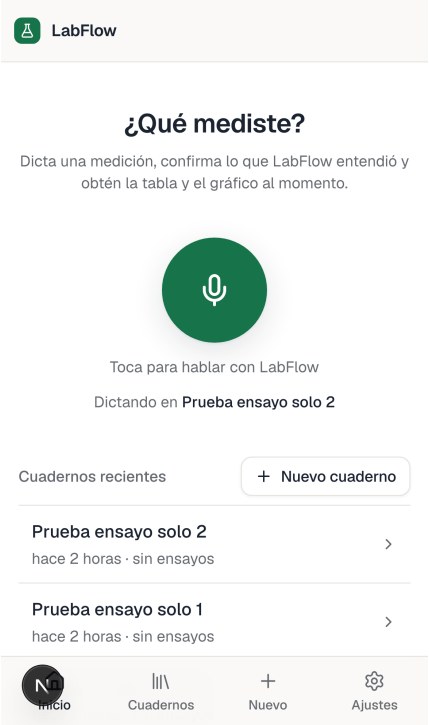
En lugar de mockups estáticos tenemos el prototipo funcionando, apoyado en un sistema de diseño documentado (web/design.md, spec 0003): tokens de color, tipografía, botones de 48 px para usar con guantes, la tarjeta de propuesta y la base del micrófono. Las capturas son del prototipo real con datos de ejemplo.

Pantalla	Qué tiene
Inicio	Micrófono grande («¿Qué mediste?»), dicta en el cuaderno activo, cuadernos recientes
Cuadernos	Lista con actividad y número de ensayos
Nuevo cuaderno	Formulario de variables, o «Leer instrucciones» desde un PDF o texto pegado
Cuaderno	Hablar o escribir una medición, la tarjeta de propuesta, y el panel con resumen, ensayos, variables y acciones
Resultados	Gráfica X vs. Y, resumen por variable (mínimo, máximo, promedio con ensayos) y mejor ensayo
Revisar variables	Agregar, editar y borrar variables, con avisos de unidad bloqueada y rango
Versión móvil	Barra de pestañas abajo, cuaderno en pestañas Capturar · Ensayos · Variables, hojas a pantalla completa, instalable

Escritorio: cuaderno con captura y panel de datos



Teléfono: inicio, capturar y resultados

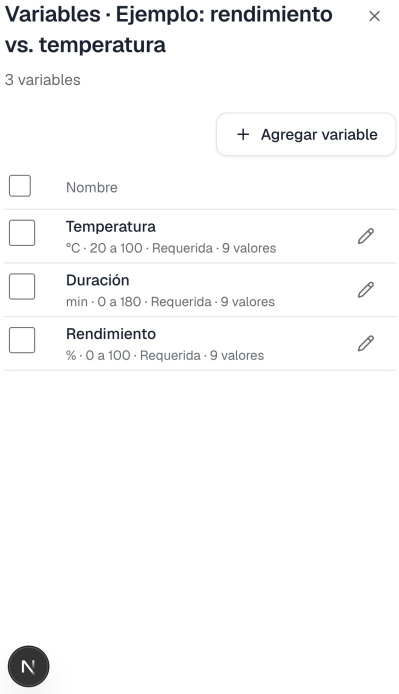


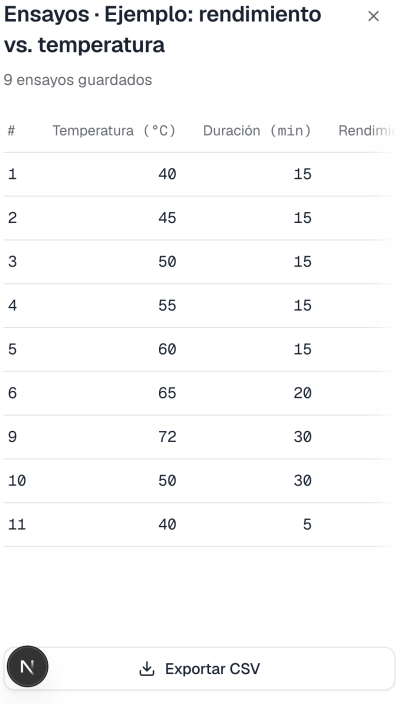




Teléfono: variables, revisar variables y tabla completa







4. Diseño arquitectónico

Qué pide
Describir cómo está construido el sistema: sus componentes y responsabilidades, cómo se comunican, dónde corre cada uno, dónde viven los datos y las claves, y por qué se eligió cada tecnología frente a sus alternativas. Suele incluir un diagrama de componentes y el flujo principal de punta a punta.

Cuál es en LabFlow AI

Capa	Responsabilidad	Tecnología	Dónde corre
Web	Pantallas, voz en el navegador, tarjeta, tabla, gráfica; versión móvil instalable	Next.js 16, TypeScript estricto, Tailwind, TanStack Query, Plotly	Vercel
API	Cuadernos, variables, captura, resultados; guarda las claves	Python 3.13, FastAPI, Pydantic	Railway
Datos	Cuadernos, variables, ensayos, mediciones, tarjetas, turnos, instrucciones	PostgreSQL (Supabase), SQLModel, Alembic	Supabase
Planificador	Convierte la llamada de herramienta del modelo en operaciones verificadas; decide qué es limpio	Código puro en Python (turn_plan)	API
Modelos de lenguaje	Leer la frase y elegir una herramienta con sus argumentos	Ollama Cloud (primario) y Claude (respaldo) detrás de una interfaz LLMProvider	Nube
Voz	Escuchar, turnos y hablar; nuestra API es el «cerebro»	ElevenLabs Agents con Custom LLM	Nube

Flujo principal (captura)

Micrófono o texto → (voz) agente de ElevenLabs transcribe y llama a **/api/voice/llm** → la API lee el contexto del cuaderno → el modelo elige una herramienta (*proponer_medicion, corregir, elegir_ensayo, confirmar, descartar, pedir_aclaracion*) → el **código** verifica cada número contra la frase, normaliza unidades y revisa rangos → si es limpio, guarda; si no, crea la tarjeta y redacta la pregunta → la web se actualiza y el agente lee la respuesta en voz alta.

Decisiones clave

- **El modelo no escribe respuestas ni calcula:** solo llena argumentos de herramientas; las respuestas en español y las estadísticas son código. Así no hay cifras inventadas.
- **Dos proveedores con respaldo:** Ollama empieza; si tarda más de 1,5 s, Claude arranca en paralelo y gana el primero válido; todo con un límite de 4,5 s y un tope de llamadas a Claude por hora.
- **Contrato tipado:** los modelos Pydantic son la fuente de verdad; *make openapi* genera los tipos de TypeScript de la web.
- **El navegador solo llama a /api en su propio dominio;** Next.js lo reenvía a FastAPI, y las claves nunca llegan al navegador.

Descartado: LangGraph (el planificador propio es más simple y verificable), SQLite local y una segunda app móvil (una sola app responsiva).

5. Diseño de pruebas

Qué pide
Planear cómo se demuestra que el sistema cumple sus requerimientos: qué niveles de prueba hay (unitarias, integración, extremo a extremo, aceptación, usabilidad), qué cubre cada uno, con qué datos y criterios de éxito, y cómo se evalúa el componente de IA (un set de evaluación con métricas y casos difíciles). Cada requerimiento debería poder trazarse a una prueba.

Cuál es en LabFlow AI

Nivel	Qué cubre	Herramienta	Hoy
Unitarias (API)	Planificador, lector de números en español, unidades, reglas de variables y respuestas; sin red ni modelo	pytest	≈ 450 pruebas en total del API
Integración (API)	Rutas reales contra Postgres, cada prueba en una transacción que se revierte; proveedor de IA falso con guion	pytest + TestClient	Incluidas arriba
Unitarias e integración (web)	Componentes, formularios, estados de error y accesibilidad (axe)	Vitest + Testing Library	562 pruebas
Extremo a extremo (teléfono)	Sin desplazamiento lateral, barra de pestañas, hojas, campos de 16 px, íconos; API simulado	Playwright (iPhone y Android)	42 pruebas en CI
Prueba en vivo	Frases reales contra Ollama y Claude; latencia ≤ 5 s	pytest -m live	Antes de cambiar modelo
Casos de error	Validaciones, ids, sesión, concurrencia, frases raras	Script contra el API	151 casos

Pruebas de aceptación (trazadas a requerimientos)

ID	Prueba	Criterio de éxito	RF
PA-01	Crear cuaderno con 3 variables	Aparece con variables y unidades	RF-01
PA-02	Dictar cinco ensayos	Los cinco quedan guardados	RF-03
PA-03	Corregir un valor mal entendido	Cambia sin duplicar el ensayo	RF-06
PA-04	Dictar un ensayo incompleto	Pregunta por el dato faltante	RF-07
PA-05	Gráfica rendimiento vs. temperatura	Los puntos coinciden con la tabla	RF-10
PA-06	Preguntar el máximo	80 %, ensayo 4, sin inventar	RF-11
PA-07	Ensayo inexistente	Dice que no hay registro	RF-11
PA-08	Recargar y reabrir	Se recuperan todas las mediciones	RF-02
PA-09	Sin micrófono, por texto	El flujo completo funciona	RF-04

Set de evaluación de la extracción

30–50 frases etiquetadas: estándar, números en palabras («sesenta y cuatro coma cinco»), orden alterado, incompleta, corrección, ambigua, fuera de rango y preguntas trampa. Métricas: exactitud por campo (≥ 90 %), cifras inventadas (0) y latencia (≤ 5 s). Pendiente automatizarlo (función 12).

6. Selección de modelos y model card

Qué pide
Justificar qué modelos usa el sistema comparando candidatos con criterios medibles (exactitud, latencia, costo, idioma) y documentar cada modelo elegido con una **model card** (Mitchell et al., 2019): detalles del modelo, uso previsto y fuera de alcance, factores relevantes, métricas, datos de evaluación y de entrenamiento, análisis cuantitativo, consideraciones éticas y advertencias o recomendaciones.

Selección

Componente	Candidatos	Elegido	Por qué
Lectura de la frase (extracción y agente)	LLM comercial por API · modelo abierto en Ollama	DeepSeek V4.1 Flash en Ollama Cloud, con Claude Haiku 5.5 de respaldo	Pasó la prueba en vivo, latencia baja y costo bajo; el respaldo cubre caídas y lentitud
Voz a texto y turnos	ElevenLabs Scribe + agente propio · ElevenLabs Agents · Whisper	ElevenLabs Agents (con nuestra API como Custom LLM)	Turnos y voz resueltos por la plataforma; la lógica sigue en nuestro código
Texto a voz	ElevenLabs	eleven_flash_v2_5	Baja latencia en español

Model card · Lector de capturas (DeepSeek V4.1 Flash vía Ollama Cloud)

Sección	Contenido
Detalles	LLM preentrenado, usado sin ajuste fino. Se llama con un prompt en español y un esquema de 6 herramientas; responde una sola llamada de herramienta. Configurable con OLLAMA_MODEL.
Uso previsto	Leer una frase de laboratorio en español y elegir la herramienta y sus argumentos (variable, número tal como se dijo, unidad dicha, ensayo).
Fuera de alcance	Calcular estadísticas, redactar respuestas al usuario, decidir guardar, dar instrucciones de seguridad o responder preguntas generales.
Factores	Números en palabras, decimales con «coma», acentos y errores de dedo, nombres abreviados de variables, frases con dos valores o sin variable clara.
Métricas	Exactitud por campo, cifras inventadas (debe ser 0), tasa de aclaraciones, latencia por turno y tasa de respaldo a Claude.
Datos de evaluación	Prueba en vivo con frases del guion; set de 30–50 frases etiquetadas por categoría (en construcción, función 12).
Datos de entrenamiento	Del proveedor, no publicados en detalle. No entrenamos ni enviamos datos para entrenar.
Análisis cuantitativo	Configurado tras acertar todas las frases de la prueba en vivo (anotado en settings.py). En pruebas de error: los rangos «23 a 71» se leen bien 3 de 3 veces tras ajustar el prompt.
Ética y riesgos	Un número mal leído podría guardarse: el código verifica que cada número aparezca en la frase, marca valores fuera de rango o convertidos y nunca usa la confianza del modelo. Datos ficticios; no se guarda audio.
Advertencias	Puede pedir aclaración de más; si tarda más de 1,5 s entra Claude. Revalidar con el set antes de cambiar de modelo o de prompt.

Model card · Respaldo (Claude Haiku 5.5, Anthropic)

Sección	Contenido
Detalles	LLM comercial por API, mismo prompt y mismas herramientas que el primario. Configurable con ANTHROPIC_MODEL.
Uso previsto	Responder cuando Ollama falla, devuelve algo inválido o no contesta en 1,5 s; también lee las instrucciones del cuaderno si Ollama no responde en 20 s.
Fuera de alcance	Igual que el primario.
Métricas	Mismas métricas; además, llamadas por hora (tope de 30) y motivo del respaldo en cada log.
Datos	Entrenamiento del proveedor; evaluación con las mismas frases.
Ética y riesgos	Igual que el primario; cada uso del respaldo queda registrado. La salida que no cumple el esquema se trata como falla.
Advertencias	Costo por llamada; el tope por hora evita gastos inesperados.

Model card · Voz (ElevenLabs Agents + eleven_flash_v2_5)

Sección	Contenido
Detalles	Plataforma de agentes de voz: reconoce el habla en español, detecta el fin del turno y habla la respuesta. Nuestra API actúa como su modelo de lenguaje (Custom LLM).
Uso previsto	Dictar mediciones con manos ocupadas y escuchar la confirmación, palabra por palabra como la redacta nuestro código.
Fuera de alcance	Decidir qué guardar o redactar respuestas propias (las herramientas del sistema están apagadas).
Factores	Ruido del laboratorio, distancia al micrófono, acentos, números parecidos («quince» y «cincuenta»).
Métricas	Errores de transcripción en números, tiempo desde que termina de hablar hasta la respuesta, tasa de caídas de la sesión.
Ética y riesgos	No se guarda audio. Si la voz falla, el texto siempre está disponible y la tarjeta muestra lo entendido antes de guardar.
Advertencias	Requiere conexión y créditos; probar con varias voces y acentos antes de la demo.